

题目编号：XH-202627 「挑战杯」揭榜挂帅擂台赛（学生赛道） 发榜单位：上海人工智能实验室

九韶

——基于 Intern-S1 的规划·求解·校验 多智能体数学推理系统

技术方案 2026 年 6 月

► 一句话概括：用 AIMO 冠军实战验证过的「多路采样 × 工具集成推理」配方筑牢正确率基本盘，再以两大原创机制攻坚剩余失败模式——「评估器优先」让智能体先构造可执行裁判再对着裁判求解，「歧义分叉」把自洽性从路径层提升到题意解读层。所有设计服务于占分 60% 的答案正确率主战场。

1 赛题解读与国内外现状

1.1 赛题本质：底模钉死，比的是智能体工程

赛题明确「聚焦推理链设计、表达清晰度与教育启发性，而非模型训练或算法优化」，全部队伍的底模统一为 Intern-S1 API——**底模相同，分差只能来自智能体架构对模型解题上限的利用率**。分数结构决定资源分配：

评审维度	权重	本方案的应对策略
答案正确性	60% （线性计分）	主战场：SC-TIR 采样求解 + 接地校验 (§4.2–4.3)
展示质量	20%	可交互 Demo、视频、报告、全程日志留痕 (§6)
推理策略与系统设计	10%	显式五阶多智能体架构 (§3)
创新性与可扩展性	10%	两大原创机制：评估器优先 + 歧义分叉求解 (§4.4–4.5)

两个关键信号：其一，同分时优先比较答案正确性——一切架构最终须回答「提了几个点的正确率」；其二，创新性评分 A 档**明示**「题型路由、过程校验、长程推理控制、外部工具结合」——官方已把创新得分点写成明牌，本方案逐项落实并给出消融证据。

1.2 模型底座分析：Intern-S1 的能力与约束

Intern-S1 为 241B 参数 MoE 科学多模态模型（激活 28B，语言主干基于 Qwen3-235B），思考模式默认开启 [1]。数学能力：AIME 2025 得分 86.0，与 DeepSeek-R1 (87.5) 相当，强于 Qwen3-235B (81.5)；但 GPQA 仅 77.3，**研究生级 STEM 题仍有显著失误率** [1]。三项工程约束实测确认后写入系统设计：

- 上下文 32K（含输出）**：长思维链 + 多轮工具调用须做上下文裁剪；
- 限流约 30 次/分钟**：多路采样必须配令牌桶限速、缓存与断点续跑；

- **官方未声明原生 JSON mode**: 结构化输出依赖客户端 schema 校验 + 修复重试, 规避「格式判零」。

1.3 难度标定: 对正确率保持清醒预期

112 道题覆盖偏微分方程、复分析、拓扑、运筹学等 18 个子领域, 难度带大致对应 TheoremQA (GPT-4 仅 52.4% [15]) 与 Putnam-AXIOM (GPT-4o 仅 19.4%, o1-preview 41.9% [16]) 之间。值得警惕的是: Putnam-AXIOM 对题目做变量换名后 GPT-4o 成绩再降 44% [16]——大模型相当比例的「会做」源于记忆。赛题明示初赛后可能**追加更新更难题目**, 本方案因此坚持「靠真实计算验证、不靠套答案」的泛化路线。

1.4 国内外方法调研: 哪些有效、哪些被证伪

(1) **工具集成推理 (TIR)**——**已验证的最大增量**。让模型在推理中穿插「写代码 → 真实执行 → 回填结果继续推理」: ToRA 在 MATH 上较 GPT-4 纯 CoT 提升 8.5pt [2]; PAL 在大数值 GSM-Hard 上 61.2% 对 CoT 约 20% [3]; MathCoder 消融显示**真实执行代码比让模型自行预测执行结果高 34pt** [4]——沙箱必须是真的。

(2) **采样聚合——零成本的免费午餐**。Self-Consistency 多数投票在 GSM8K/AQuA 上提升 11~18pt [5]。前提是先做**答案等价归一** ($1/2$ 与 0.5 、 $\frac{\sqrt{2}}{2}$ 与 $\sin 45^\circ$ 判同), 否则等价答案拆票, 投票失效——本赛题答案多为表达式, 归一是刚需 (Math-Verify [14])。

(3) **实战配方——AIMO 数学奥赛冠军方案**。AIMO Progress Prize 1 冠军采用 **SC-TIR: 每题采 $N=48$ 条推理链, 每条至多 $M=4$ 轮代码执行自纠, 归一后多数投票**, 将同模型成绩从纯 CoT 的 8/50 拉至 29/50, 且显著降低方差 [6]。AIMO-2 冠军引入 GenSelect (让模型对候选解生成式比较选优) 与自适应 TIR (按题决定是否写代码) [7]。这是与本赛题形态最接近、被实战验证的配方, 本方案以其为主干。

(4) **被证伪的路线——纯文本自我纠错**。Huang 等证明**无外部反馈时 LLM 的内在自我纠错无效甚至降分** [8]; CRITIC 进一步表明自修正增益几乎全部来自外部工具反馈 [9]。因此本方案的校验一律「接地」: 数值代回、沙箱报错回填、候选比较, **不做无工具的「再想一遍」**。搜索类方法中, ToT [10] 对开放解析题 ROI 低, rStar-Math 类 MCTS+PRM 需训练 [11]、超出赛题边界, 均不采用 (仅借鉴其步骤评分思想)。


(5) **进化程序搜索——面向「可验证目标」题型的新武器**。DeepMind AlphaEvolve 以「LLM 变异程序 + 自动评估器打分 + 种群进化」在矩阵乘法算法、kissing number 等数学问题上取得超越人类已知最优的发现 [12]; 其开源复刻 OpenEvolve 提供可直接对接 OpenAI 兼容 API 的实现 [13]。该范式恰好覆盖本赛题中**运筹优化、组合构造类「解可机器判优」的题目**, 并呼应赛题「促进 AI 在理论发现中的应用」的愿景。

2 关键技术问题分析

技术问题	难点本质	本方案对策
P1 题型异质	18 子领域, 答案形态横跨数值/表达式/集合/构造, 求解与判分策略迥异	题型路由: 领域 $\times$ 答案形态 $\times$ 难度 三维分类, 分派求解链与预算 (§4.1)
P2 自纠错幻觉	无外部反馈的自我纠错被证伪 [8], 纯 prompt 校验是无效投入	接地校验: 数值代回 + 沙箱反馈 + GenSelect 仲裁 (§4.3)
P3 预算约束	限流 30 次/分 $\times$ 多路采样 $\times$ 校验回溯, 调用量三重放大	动态预算: 按难度分配 N ; 令牌桶 + 缓存 + 断点续跑 (§4.1/§5)
P4 格式判零	JSON 解析失败即该题零分, API 无原生 JSON mode	schema 客户端校验 + 自动修复重试 + function calling 锁格式 (§4.5)
P5 追加新题	初赛后可能加题, 过拟合 112 题的方案会暴露	不背答案: 真实计算验证路线 + 自建泛化自测集 (§5)

3 总体技术路线

系统为「路由 $\rightarrow$ 求解 $\rightarrow$ 校验 $\rightarrow$ 表达」四层多智能体流水线: **路由层**为每道题判定类型并定制预算; **求解层**以 N 路并行的「推理 + 真实代码执行」推理链产出候选答案 (解题规划内嵌于每条链的首轮输出), 构造/优化类题分流至进化求解器; **校验层**对候选答案先等价归一、再机器验证、后投票仲裁, 失败时携带原因回溯求解层 (至多 2 轮); **表达层**产出合规 JSON 与启发式讲解。层间传递的数据已在图中标注:



3.1 单题数据流走查（以一道中档常微分方程题为例）

- 路由（1 次调用）**：判定〈微分方程，表达式型答案，中档〉，查预算表得 $N=16$ 、 $M \leq 4$ 、温度 0.7、仲裁方式「投票 + 平票 GenSelect」。若判定为构造/优化类（如「求最小的 n 使得……」），整题改走进化求解器 (§4.4)，后续步骤 2-5 不再执行。
- 求解（16 路并行）**：每路推理链首轮先输出解题计划（用什么方法、分几步、哪步需要计算）；随后进入工具循环——写 SymPy 代码求解 → 沙箱真实执行 → 若报错则 traceback 回填修正（唯一被证实有效的自纠形态，§1.4(4)）→ 续推；至多 4 轮后每路给出一个候选答案与完整推理链。
- 等价归一**：Math-Verify 将 16 个候选化为规范形式，等价变形（同一通解的不同写法）合并为答案簇——假设得到 3 簇，票数 11/4/1。
- 数值代回**：每簇取代表解，抽数值点代回原方程与初值条件机械验证，不满足者整簇剔除——假设 4 票簇被剔除。
- 投票决议**：幸存簇中 11 票多数胜出；若平票或全部簇被剔除，交 GenSelect 仲裁智能体比较候选推理链选优；仍无合格解时，将失败原因（如「候选解均不满足初值条件」）拼入 prompt 回到第 2 步重解，**至多回溯 2 轮**，超限则输出当前最优解并在日志中标注低置信。
- 表达**：最终答案与已验证推理链交输出智能体，生成 schema 合规 JSON（本地校验失败自动修复重试）与三段式启发讲解（动机 → 关键洞察 → 常见误区）。

3.2 工程底座

基于官方基线 lagent [17] 的 OpenAI 兼容后端与 PythonInterpreter 组件，编排逻辑自研——既继承官方基线，又保证比赛逻辑（动态预算、JSON 鲁棒、限流调度）完全可控。

4 关键模块设计

各模块的输入/输出接口与实现载体汇总如下，随后逐一展开：

模块	输入	输出	实现载体
路由	题面	〈领域, 形态, 难度〉+ 预算	Intern-S1 单次调用, function calling 锁分类 schema
a SC-TIR	题面 + 预算 (N, M, T)	N 份〈候选答案, 推理链〉	asyncio 并行 + 子进程沙箱 + 令牌桶限流
b 进化求解	题面 + 自动生成的 评估器	已验证最优解 + 得分	OpenEvolve 对接书生 API
聚合校验	候选答案集	最终答案 + 置信度	Math-Verify/SymPy + 沙箱代回 + 仲裁调用
表达	最终答案 + 已验证 推理链	合规 JSON + 讲解文本	pydantic 校验 + 修复重试循环

4.1 题型路由与动态预算分配

功能拆解：(a) 子领域分类 (18 类)；(b) 答案形态分类 (数值/表达式/集合区间/证明/构造优化, 共 5 类, 决定后续校验模板的选择)；(c) 难度分档 (易/中/难)；(d) 查表定预算；(e) 低置信兜底。

实现要点：单次调用、温度 0, 以 function calling 强制输出〈领域, 答案形态, 难度, 是否需代码〉四字段；提示词内嵌 18 子领域定义及各 1 个分类示例；模型自报分类置信度低于阈值时一律按「中档」处理 (宁可多花预算, 不可漏判难题)；路由结果落盘缓存, 全量重跑不重复分类。难题预算对齐 AIMO-1 实测饱和点 ($N=48$ 后增益趋零 [6])：

难度档	采样 N	TIR 轮数 M	温度	仲裁方式
简单	4	≤ 2	0.3	多数投票
中档	16	≤ 4	0.7	投票 + 平票 GenSelect
困难	≤ 48	≤ 4	0.7~1.0	GenSelect
可验证构造/优化	进化搜索 (§4.4)	—	—	评估器目标函数判优

4.2 SC-TIR 求解引擎 (正确率的主引擎)

功能拆解：(a) 分领域提示模板库；(b) 单链推理状态机；(c) Python 沙箱；(d) 上下文管控；(e) 并行调度与缓存。每条推理链为「思考 → 写代码 → 沙箱执行 → 观察结果/traceback → 继续」的多轮循环：符号积分、级数、留数、特征值交给 SymPy, 数值验证交给 SciPy/NumPy, 线性/整数规划交给 cvxpy/PuLP——把模型最易出错的机械计算外包给确定性工具 (MathCoder 消融 +34pt 的来源 [4])。

实现要点：

- **提示模板库：**system prompt = 领域专家角色 + 工具协议 (``python 代码块约定) + 答案格式约定 (终答置于 \boxed{ })；按 18 子领域维护模板并注入领域指引 (如复分析题提示优先考虑留数定理与围道选取)；
- **单链状态机：**「计划 → (代码 → 执行 → 观察) * → 终答」；正则解析输出中的代码块, 已给出 boxed 终答且无新代码块即终止；
- **沙箱：**独立子进程执行, 超时 30s、内存上限 2GB、import 白名单 (sympy/numPy/scipy/cvxpy 等)、禁网络与文件写；stdout/traceback 截断至 2000 字符回填；
- **自适应 TIR：**拓扑、抽象代数等纯推理题不强制写代码 (AIMO-2 经验：部分题代码无益 [7])，由路由 need_code 字段控制开关, 省下的预算让给采样；
- **上下文管控：**针对 32K 限制, 每轮仅保留题面、解题计划与最近一轮代码及输出, 更早轮次压缩为单句摘要；
- **并行调度：**asyncio 并发 + 令牌桶 (默认 30 次/分, 按实测调整)；所有调用以〈题号, 链号, 轮次, prompt 哈希〉为键落盘缓存, 支持断点续跑；
- **提前终止：**前 8 路完成后若最大答案簇票数 ≥ 6 且通过数值代回, 停采剩余路数——按 AIMO-1 的票数分布估计可节省约三成调用量。

4.3 接地校验与仲裁（第二增量，对应评分 A 档「过程校验」）

依据 §1.4(4) 的证据，校验全部绑定外部反馈，按成本递增分三层：

1. **等价归一**：Math-Verify 抽取 boxed 答案 → 解析为 SymPy 对象 → 以 `simplify(a-b)=0` / `equals()` 两两判等聚簇 [14]，杜绝等价拆票；解析失败的候选降级为字符串规范化比较；
2. **数值代回**：按路由给出的答案形态选验证模板——方程/ODE 解：随机抽 3~5 个数值点代入查残差 $< 10^{-6}$ ；优化题：复核可行性与目标值；证明题等不可机械验证形态跳过本层，仅走投票与仲裁。验证代码同走沙箱执行；
3. **GenSelect 仲裁与有界回溯**：平票或全部簇被剔除时，仲裁智能体在一次调用内对 2~16 个候选（题面 + 各候选答案与推理链摘要）做生成式比较选优 [7]；仍失败则将结构化失败原因〈阶段，现象，建议〉拼入重解 prompt，回溯轮采样预算减半，上限 2 轮，防止预算失控。

4.4 创新点一：评估器优先范式（Evaluator-First）——先造裁判，再求解

核心思想：利用数学问题的**验证不对称性**（验证一个解远比求出它容易），在求解之前先派评估器构造智能体**从题面自动合成「可执行裁判」**，把开放求解转化为对着裁判的搜索——裁判是程序而非模型，从根本上绕开「LLM 自我校验不可靠」的缺陷 (§1.4(4))。按题型自动选择三类裁判：

- **数值裁判 (numeric oracle)**：积分/ODE/概率题直接数值求解原问题（数值积分、RK 数值解、蒙特卡洛），得到采样点真值，所有候选解析解须与真值吻合——把大量「不可验证」题转化为可验证题；
- **残差/可行性检查器**：方程解代回查残差，优化解复核可行性与目标值 (§4.3 的接地校验即本范式的退化形式)；
- **目标打分器**：开放构造/优化题的连续评分函数。

决策机制：候选解先过裁判——被数值真值否决者直接出局；幸存者投票按「**通过的机器检查数**」加权而非一人一票（证据加权投票）。采样调度按**投票熵自适应**：全票一致即停采，分歧大则追加至预算上限，把有限调用让给真正不确定的题。

进化搜索的定位 (诚实评估)：AlphaEvolve 式进化 [12, 13] 仅在「开放构造/优化且裁判可连续打分」的题型上启用（OpenEvolve 直连书生 API，单题预算 ≤ 80 次调用）；考试型优化题**优先精确求解器**（cvxpy/暴力枚举一轮即解），进化是兜底搜索后端而非主力——其在本系统中的真正贡献是「评估器」这一组织原则本身，并保留为决赛「长程推理控制」展示与官方开放题的期权。

4.5 创新点二：歧义分叉求解（Interpretation Forking）——解读层的自治性

实证动机 (来自本系统调试日志)：实测中发现典型失败——「divide a set of 8 elements into 5 non-empty ordered subsets」被模型理解为「5 个带标号的桶」（算得满射数 126000，计算无误），而题意是「内部有序的子集」（Lah 数 $L(8, 5)=11760$ ）。**计算全对、审题错了**；且此类错误**采样再**

多推理链也无法纠正——所有链共享同一误读，误差完全相关，路径级 Self-Consistency 的独立性假设失效。

机制：路由层增加歧义检测；标记为歧义风险的题（预计 <10%）先由审题智能体枚举合理解读（≤3 种），采样预算按解读分组分配，各解读组内独立求解投票；仲裁层依据三类线索选解读——答案形态约定（如选项/整数提示）、量纲与数量级合理性、各解读组内部一致性强度。本质是把 Self-Consistency 从路径层提升到**解读层**，以分叉实现误差去相关。

4.6 结构化输出与启发式讲解

输出智能体按官方 schema 生成 JSON：以 pydantic 定义官方字段模型做本地强校验，失败时将 ValidationError 信息回填重试（≤3 次，必要时以 function calling 锁定字段结构），仍失败则启用规则兜底（从已验证推理链中正则抽取答案填入必填字段）——多级防线将 P4「格式判零」风险归零。讲解生成采用「三段式启发模板」：为什么想到这个方法（动机）→ 关键洞察（转折点）→ 常见误区（教育性），由模型基于已验证的推理链单次调用润色生成——讲解服务主观分，**不占难题求解预算**。

5 评测工程与量化预期

评测基础设施先行：本地 runner 支持并发限流（令牌桶 30 次/分）、调用缓存、断点续跑、全量日志落盘（同时满足赛规「日志可复核」要求）；自建近似评分器（Math-Verify + 数值容差）使每次迭代可量化。

失败分析驱动迭代：每周全量评测输出 18 子领域正确率热力图，定向攻坚最弱领域；预留自选难题集做泛化自测，对冲追加新题风险（P5）。

预算可行性：中档配置（ $N=16, M=4$ ）全量一轮约 7200 次调用，在 30 次/分限流下约 4 小时完成，支持每晚全量回归。

消融计划与预期（文献推算，以实测为准；B0 摸底是 6 月的第一个里程碑）：

配置	组成	文献依据	预期增量
B0	裸 CoT 单链（基线摸底）	—	—
B1	B0 + TIR 沙箱	TIR 系列 [2, 3, 4]	+6~12pt
B2	B1 + SC 投票（ $N=16$ ）+ 归一	SC/AIMO-1 [5, 6]	+8~15pt
B3 完整版	B2 + 评估器优先 + 歧义分叉	CRITIC [9] + 自有失败分析	+3~6pt

6 实施计划与决赛扩展

阶段	时间	内容
M1	6 月	6/30 前完成报名 ；API 实测（限流/thinking/JSON）；harness 搭建；B0 摸底
M2	7 月	TIR 沙箱、SC 投票、Math-Verify 归一逐周上线；每周全量回归 + 热力图
M3	8 月上	接地校验、GenSelect、进化求解器；攻坚短板领域
M4	8 月下	稳定性三连跑验方差；泛化自测；技术报告与 Demo 初版
M5	9 月初	代码冻结、最终全量跑、打包提交（报告 + JSON 日志 + 代码）
决赛	10–11 月	多智能体协作叙事完善；Web Demo（推理树与校验过程可视化、讲解模式）；视频

初赛架构本身已是多智能体系统（路由/规划/求解/校验/讲解各司其职），决赛阶段的重心是**可交互展示**：Streamlit Web Demo 实时呈现题型路由决策、 N 路推理链的分歧与聚合、校验智能体的代回验证过程，以及进化求解器的种群进化曲线——把系统内部的「推理民主」过程变成评审可见的展品，同时覆盖决赛三个可选挑战方向（长程推理、题型路由 solver、过程校验自主调控）。

参考文献

- [1] Bai L., Cai L., et al. Intern-S1: A Scientific Multimodal Foundation Model. arXiv:2508.15763, 2025.
- [2] Gou Z., Shao Z., Gong Y., et al. ToRA: A tool-integrated reasoning agent for mathematical problem solving. *ICLR*, 2024.
- [3] Gao L., Madaan A., Zhou S., et al. PAL: Program-aided language models. *ICML*, 2023.
- [4] Wang K., Ren H., Zhou A., et al. MathCoder: Seamless code integration in LLMs for enhanced mathematical reasoning. *ICLR*, 2024.
- [5] Wang X., Wei J., Schuurmans D., et al. Self-consistency improves chain of thought reasoning in language models. *ICLR*, 2023.
- [6] Beeching E., Huang S. C., Jiang A. Q., et al. How NuminaMath won the 1st AIMO Progress Prize. Hugging Face Blog, 2024.
- [7] Moshkov I., Hanley D., Sorokin I., et al. AIMO-2 winning solution: Building state-of-the-art mathematical reasoning models with OpenMathReasoning dataset. arXiv:2504.16891, 2025.
- [8] Huang J., Chen X., Mishra S., et al. Large language models cannot self-correct reasoning yet. *ICLR*, 2024.
- [9] Gou Z., Shao Z., Gong Y., et al. CRITIC: Large language models can self-correct with tool-interactive critiquing. *ICLR*, 2024.
- [10] Yao S., Yu D., Zhao J., et al. Tree of Thoughts: Deliberate problem solving with large language models. *NeurIPS*, 2023.
- [11] Guan X., Zhang L. L., Liu Y., et al. rStar-Math: Small LLMs can master math reasoning with self-evolved deep thinking. arXiv:2501.04519, 2025.
- [12] Novikov A., Vũ N., Eisenberger M., et al. AlphaEvolve: A coding agent for scientific and algorithmic discovery. arXiv:2506.13131, 2025.
- [13] Sharma A. OpenEvolve: An open-source evolutionary coding agent. <https://github.com/codelion/openevolve>, 2025.
- [14] Hugging Face. Math-Verify: A robust mathematical expression evaluation system. <https://github.com/huggingface/Math-Verify>, 2025.
- [15] Chen W., Yin M., Ku M., et al. TheoremQA: A theorem-driven question answering dataset. *EMNLP*, 2023.

- [16] Gulati A., Miranda B., Chen E., et al. Putnam-AXIOM: A functional and static benchmark for measuring higher level mathematical reasoning. arXiv:2508.08292, 2025.
- [17] InternLM Team. Lagent: A lightweight framework for building LLM-based agents. <https://github.com/InternLM/lagent>, 2024.